

به نام خدا

« پروژه اول »

بوتکمپ تحلیل داده کوئرا

بهار ۱۴۰۵



مقدمه و آشنایی با مسئله

پروژه اول بوت کمپ براساس داده‌های سایت <https://www.basketball-reference.com> طراحی شده است. هدف این پروژه آشنایی بیشتر شما با آموخته‌های بوت کمپ تا به اینجا است. هم‌چنین یادگیری یک مبحث کافی نیست و باید در حیطه عمل آن را به کار بست. در این پروژه با استفاده از جمع‌آوری داده‌های سایت بسکتبال رفرنس به تحلیل‌های آماری می‌پردازیم و به برخی از سوالات جالب پاسخ می‌دهیم. این پروژه دارای سه مرحله اصلی با تمرکز بر جمع‌آوری، ذخیره‌سازی، تحلیل داده می‌باشد.

1. در مرحله اول، به جمع‌آوری دیتا از سطح اینترنت با استفاده از Web Scraping می‌پردازیم.
2. در مرحله دوم، به ذخیره‌سازی دیتای استخراج‌شده در دیتابیس می‌پردازیم. در این قسمت نیاز است درباره‌ی چگونگی انجام این کار به بهترین شکل ممکن، ایده‌پردازی شود.
3. در مرحله سوم، به دنیای آمار سفر کرده و با استفاده از آزمون‌ها و نمودارهای آماری، به بررسی و شناخت بیشتر داده‌های پروژه می‌پردازیم.

توجه داشته باشید که در کنار مهارت‌های سخت، بخش زیادی از نحوه‌ی پیش‌برد پروژه به مهارت‌های نرم شما مربوط است. بنابراین در طول پروژه نیاز خواهید داشت تا با کار تیمی و تعامل و پشتیبانی از یکدیگر، به بهترین نحوه ممکن با هم‌تیمی‌های خود در ارتباط باشید و به پیشرفت پروژه کمک کنید. مشارکت شما به‌عنوان عضوی از تیم توسط منتور گروه مورد ارزیابی قرار خواهد گرفت.

ممکن است بخش‌های مختلف پروژه وابسته به همدیگر باشند، بنابراین در اجرای هر بخش سعی کنید نیازمندی‌های بخش‌های دیگر را مطالعه کرده و تامین کنید.

فاز اول: استخراج داده

در این بخش شما با استفاده از Web Scraping که در پایتون و در تمرین اختیاری آموختید به استخراج داده‌های زیر می‌پردازید:

نکته مهم: در نظر داشته باشید توضیحات زیر مثال‌هایی برای فهم بهتر و آشنایی با مسئله هستند. ساختار اصلی چیزی است که شما و گروه‌تان باید برای آن به نتیجه برسید. اما می‌توانید از داده‌های متنوع دیگر برای بهبود روش‌تان استفاده کنید.

- بازیکن: اسم و فامیل، تاریخ تولد(سن)، قد، ملیت، موقعیت، شوت، باشگاه فعلی، قد، وزن و ...
- باشگاه: اسم، تاریخ تاسیس، نام لیگ، مربی، بازیکنان، میانگین سنی بازیکنان، ارزش باشگاه، ارزش بازیکنان، افتخارات، نام استادیوم و ...

با توجه به سوالاتی که در ادامه مطرح شده استخراج تمامی اطلاعات مورد نیاز برای این سوالات الزامی است.
در صورت استخراج اطلاعات بیشتر از موارد خواسته شده در سوالات مشمول نمره اضافه خواهید شد.

فاز دوم: طراحی دیتابیس

کاری که در این فاز از پروژه باید انجام شود، ساختن دیتابیس و جداول مورد نیاز و ایجاد ارتباط بین جداول‌هاست، در ادامه توضیحاتی را برای این قسمت آورده‌ایم:

1. طراحی دیتابیس:

- الف) موجودیت‌های اصلی در داده‌ها مانند بازیکنان، تیم‌ها، لیگ و مسابقات را تعیین کنید.
- ب) روابط بین موجودیت‌ها را تعیین کنید، مانند رابطه بین بازیکنان و تیم‌ها.

ج) ویژگی‌های داده خاصی را که باید برای هر موجودیت ذخیره شود، تعیین کنید، مانند ویژگی‌های بازیکن (سن، موقعیت، اهداف، و غیره)، ویژگی‌های تیم (نام، کشور، و غیره) و آمار بازی‌ها و ...
د) از تکنیک‌های نرمالایز کردن برای حذف افزونگی داده‌ها و اطمینان از یکپارچگی داده‌ها استفاده کنید.

2. انتخاب ابزار و تکنولوژی دیتابیس:

یک سیستم مدیریت پایگاه داده رابطه‌ای (RDBMS) را انتخاب کنید که به بهترین وجه با نیازهای شما مطابقت دارد، مانند SQL Alchemy، MySQL یا مقیاس‌پذیری و الزامات عملکرد برنامه را در نظر بگیرید تا مطمئن شوید که RDBMS انتخابی می‌تواند حجم داده و حجم کاری مورد انتظار را مدیریت کند.

3. جمع‌آوری و ذخیره‌ی داده‌ها در دیتابیس:

با استفاده از ابزار Web Scraping و آموخته‌های خود داده‌های مورد نظر را استخراج نمایید.

4. آماده‌سازی داده برای تحلیل و آموزش مدل:

الف) داده‌های مورد نیاز را برای تجزیه و تحلیل آماری از پایگاه داده بازیابی کنید. کوئری‌های SQL را بنویسید تا داده‌های مربوطه را بر اساس تحلیل خاص یا الزامات مدل‌سازی استخراج کنید.
ب) هر مرحله پیش‌پردازش اضافی مورد نیاز روی داده‌ها برای تحلیل آماری، مانند مدیریت داده‌های از دست‌رفته، اسکیل کردن یا نرمال‌سازی ویژگی‌ها و رمزگذاری متغیرهای طبقه‌بندی‌شده را انجام دهید.

نکته مهم: پیشنهاد می‌شود ابتدا فاز سوم را مطالعه و بررسی کامل کرده و سپس برای فاز اول و دوم تصمیم‌گیری نمایید.

فاز سوم: تحلیل‌های آماری

در این بخش، به کمک دانش آماری می‌خواهیم به تعدادی از سوال‌ها پاسخ دهیم؛ برخی از سوالات برای درک و یافتن شهود از داده‌ها پرسیده شده است، برخی دیگر از سمت یک شخص خاص، و در انتها تعدادی فرضیه مطرح شده است که شما باید آن‌ها را اعتبارسنجی کنید.

در قسمت‌های مختلف این بخش، از شما خواسته شده است که به طراحی معیار بپردازید. همان‌طور که در کلاس‌های آمار شما مطرح شد، برای پاسخ به سوال‌های آماری، یک معیار دقیق (metric) برای سنجش به شما داده می‌شود و شما پس از دریافت این معیار، می‌توانید بررسی خود را شروع کنید. اما گاهی پیش می‌آید که کارفرما به شما معیار درستی ندهد و از شما بخواهد که خود، بر اساس داده‌هایی که در اختیار دارید، یک معیار طراحی کنید.

شما در این فاز، باید با توجه به داده‌های داده‌شده و درخواست کارفرما، معیارهای متفاوتی طراحی کنید. توجه کنید که هیچ معیاری «کاملاً درست» نیست، و همین که معیار شما بر پایه‌ی حداقلی از استدلال باشد و داده‌های مهم را در نظر گرفته باشد، مورد تایید خواهد بود.

آمار توصیفی

در این بخش می‌خواهیم با بررسی داده‌های سایت <https://www.basketball-reference.com>، شهودی نسبت به وضعیت لیگ NBA بسکتبال داشته باشیم.

- توزیع قد بازیکنانی که در لیست Michael Jordan Trophy حضور دارند را با ۵۰ بازیکن برتر فصل با توجه به آمار فصل‌ها از فصل ۲۰۱۹-۲۰۲۰ تا پایان ۲۰۲۳-۲۰۲۴ تهیه کنید. (برای هر فصل به صورت مجزا نیاز به بررسی نیست)
- توزیع میزان تجربه افراد فعال، در تیم قهرمان و قد در دو فصل آخر را با توزیع میزان تجربه و قد ۱۵ بازیکن برتر آن فصل مقایسه کنید
- باشگاهی می‌خواهد در فصل بعدی شروع قوی داشته باشد و معتقد است اگر بر روی پوزیشنی سرمایه‌گذاری کند که معمولاً هوش بسکتبالی خوبی بالایی نیاز دارد و بازیکنی توانا برای این پوزیشن خریداری کند، می‌تواند شانس خود را برای موفق در فصل بعدی افزایش دهد. به همین دلیل می‌خواهد بازیکنی در پوزیشن Point Guard خریداری کند که توانایی بالایی داشته باشد. معیار توانایی برای این باشگاه، وجود بازیکن در لیست Michael Jordan Trophy می‌باشد و بازیکنی که حضور بیشتری داشته، اولویت بالاتری دارد. لیستی از بازیکنان مناسب برای خرید با توجه به آمار فصل‌ها از فصل ۲۰۱۹-۲۰۲۰ تا پایان ۲۰۲۳-۲۰۲۴ تهیه کنید و ۳ پیشنهاد به این باشگاه ارائه دهید.

تست فرض

یکی از کاربردهای مهم آمار، تشخیص و اعتبارسنجی فرضیه‌هایی است که مدیران، مربیان و کارشناسان ارائه می‌دهند. از آن‌جا که اکثریت این فرضیه‌ها تحت تاثیر المان‌هایی زیادی هستند، نمی‌توان بدون انجام آزمایش و بررسی داده‌ها پاسخ مسائل را مشخص کرد. برای مثال، به فرضیه‌ی زیر توجه کنید:

مهاجم‌های قد بلند، گل‌های بیشتری به نسبت مهاجم‌های قد کوتاه به ثمر می‌رسانند.

در جهت تایید این ادعا می‌توان گفت: به دلیل این که مدافعان معمولاً قد و قامت بلندی دارند، در صورتی که مهاجم‌ها از نظر فیزیکی قوی نباشند، نمی‌توانند از پس مدافعان بر بیایند. در نتیجه، این مهاجم‌ها در توپ‌های هوایی یا تقابل‌های یک به یک ضعیف هستند و به همین دلیل گل‌های کمتری می‌زنند.

اما در رد این ادعا نیز می‌توان گفت: مهاجم‌های ریز نقش، معمولاً از چابکی و سرعت بیشتری برخوردار هستند و به همین دلیل می‌توانند با حرکت‌های انفجاری و در عمق، گل‌های بیشتری به ثمر برسانند!

در نتیجه، نمی‌توان برای پاسخ دادن به فرضیه‌ها صرفاً به تعدادی دلیل و توجیه اکتفا کرد و تنها راه علمی درست، استفاده از آمار برای اعتبار سنجی این فرضیه‌هاست. در این بخش، تعدادی فرضیه برای شما تعریف شده است که شما باید آن‌ها را مورد آزمایش و بررسی قرار دهید.

فرضیه‌ی اول

ادعا می‌شود میانگین چابکی افرادی که در ۲۰ نفر اول هر فصل حضور دارند، نسبت به گذشته افزایش یافته‌است. تعریف چابکی را می‌توان نسبت قد به وزن افراد دانست. برای آزمایش این ادعا، از مقایسه داده‌های فصول ۲۰۲۲-۲۰۲۳ تا ۲۰۲۴-۲۰۲۳ با داده‌های ۲۰۲۱-۲۰۲۲ تا ۲۰۲۲-۲۰۲۳ بهره بگیرید.

فرضیه‌ی دوم

کارشناسی مدعی می‌شود امروزه به دلیل پیشرفت و بهبود شرایط، استفاده و شکوفا شدن توانایی ذاتی افراد نسبت به گذشته بهبود یافته‌است و برای مثال، میزان میانگین توانایی ذاتی بازیکن‌های تیم قهرمان ۲ فصل اخیر، از ۲ فصل قبلی آن بیشتر بوده‌است. او تعریف توانایی ذاتی افراد را نسب میزان تجربه به سن فرد اعلام می‌کند. این ادعا را برای مثال ذکر شده و برای بازیکنان فعال آن فصل تیم، بررسی نمایید.

بخش‌های امتیازی

نکته‌های کلی

- کدهای خود را خوانا و تمیز بنویسید.
- مهم‌ترین بخش این پروژه، تحلیل و تفسیر شما از شرایط مسئله و نتایج آن است. باید بتوانید برای هر کدام از انتخاب‌های خود در طول مسیر، دلیلی موجه و علمی داشته باشید. ارائه‌ی شما نیز باید بر همین محور باشد، یعنی روند حل مسئله، نتایج و تحلیل و تفسیر را ارائه دهید، نه توضیح کد.
- به نکات ذکر شده در ارتباط با نحوه‌ی ارسال فایل در صفحه‌ی پروژه در کلاس توجه فرمایید.

بخش امتیازی (بیشینه: ۲۵ نمره)

- مستندسازی غنی و مناسب در نت‌بوک‌ها، کد نویسی تمیز و استفاده از OOP و غیره
- استفاده از گیت و مشارکت فعال در آن
- طراحی آزمون‌های آماری دیگر.
- اطلاعات و نمودارهای مفید بیشتر
- ارائه‌ای جذاب با بهره‌گیری از خط داستانی و استفاده از ابزارهای مناسب ارائه

موفق باشید 😊